

阿克曼转向模型

假设: ① 车轮与地面只有滚动摩擦 (无侧滑)

② f 方向同车轮方向


↓
四轮为纯滚动

同一刚体的角速度
处处相等

↓
简化为两轮模型
(内外侧轮的转角平均计算)


↓
四个轮的法线交于车身转动的圆心

动力学自行车



我们需要算出
车在全局坐标系下的
坐标 X_{Base} , Y_{Base}
及航向角 ψ

$$\begin{cases} V_{xB} = \frac{dX_B}{dt} = V_x \cdot \cos \psi & (1) \\ V_{yB} = \frac{dY_B}{dt} = V_x \cdot \sin \psi & (2) \\ \omega = \frac{d\psi}{dt} = \frac{V_y}{L} = \frac{V_x \tan \delta}{L} & (3) \end{cases}$$



车的状态空间方程



我们还需要将连续的微分方程转化
为离散的差分方程

$$X_{k+1} = X_k + X' \cdot \Delta t$$

PID一般用在
控制车辆纵向加减速


PID

$$u(x) = k_p e(t) + k_i \int_0^t e(t) dt + k_d \frac{de(t)}{dt}$$


当实际产生了误差 e 时, 才出手控制

而且出手控制时, PID 是不知道车会往哪跑的。


因为没有用到 **上述的状态空间模型** (无模型控制方法)



纯跟踪算法 (基于 Ackmen)



设出中间量 α 和 R



$$\begin{cases} \tan \delta = \frac{L}{R} \\ e = L_d \sin \alpha \\ \frac{L_d}{\sin 2\alpha} = \frac{R}{\sin(\frac{\pi}{2} - \alpha)} \end{cases} \Rightarrow \delta = \arctan\left(\frac{2L}{L_d^2} e\right)$$

当 δ 较小时, $\approx \frac{2L}{L_d^2} e = k_p \cdot e$

$$R = \frac{L_d}{2 \sin \alpha}$$


这不是 P 控制器吗?!

困难在于前瞻距离 L_d 的选择!

而且也无法推算下一刻车在哪! (只有几何约束, 没有时间约束)

转向执行器还有延迟.....

最优控制



求成本函数的最小值:

无约束优化之: 梯度下降

在 $P(x, y)$ 处, 移动 $\Delta \vec{P} = (\Delta x, \Delta y)$

$$F(P + \Delta \vec{P}) \approx F(P) + \nabla F(P)^T \cdot \Delta \vec{P} + o(\Delta \vec{P})$$


↓
下降最快的方向是 $\nabla F(P)$ 的反方向

$$\therefore \Delta \vec{P} = -\eta \nabla F(P), \eta \text{ 为常数} \\ (\text{学习率?!})$$

判断最优:

- ① $\|\nabla F(P)\| < \epsilon$, 梯度极小.
- ② $|f(P_{k+1}) - f(P_k)| < \epsilon$, 变化小, 函数趋于稳定
- ③ 设迭代次数, 取结束后的点

带约束: 等式约束与不等式约束
(限定曲面) (限定曲面范围)



① 等式约束:

$$g(P) = 0$$

最优解 P^* 附近

① 任意移动方向 $\Delta \vec{P}$ 与平面 B 相切

$$\nabla g(P^*)^T \cdot \Delta \vec{P} = 0$$

② $F(P)$ 的方向导数也为 0

$$\nabla F(P^*)^T \cdot \Delta \vec{P} = 0$$

$\therefore \nabla g(P^*)^T, \nabla F(P^*)^T$ 垂直同一切平面

$$\nabla F(P^*)^T - \lambda \nabla g(P^*)^T = 0 \quad (\text{二者平行})$$

$$\mathcal{L}(P, \lambda) = F(P) - \lambda g(P)$$

$$\Rightarrow \begin{cases} \frac{\partial \mathcal{L}}{\partial P} = \nabla F(P^*) - \lambda \nabla g(P^*) = 0 \\ \frac{\partial \mathcal{L}}{\partial \lambda} = -g(P) = 0 \end{cases} \quad (\text{就是原约束})$$

② 不等式约束

$$h(P) \leq 0$$

① 限定范围内部最优解: $h(P) < 0$

$$\nabla F(P^*) = 0 \quad (1) \quad \text{此时应有 } \mu = 0$$

② 边界上: 我说就是等式约束 $h(P) = 0$

区别在于: 等式约束下, λ 可为任意数 此时应有 $\mu \geq 0$

不等式约束下, $-\nabla F(P^*)$ 必须指向约束区域的外部, 即 $h(P) > 0$

(指向内部, 那最优不就是在内部了吗...)

$$-\nabla F(P^*) = \mu^* \cdot \nabla h(P^*) \quad (2), \quad \mu^* \geq 0$$

$$\mu^* \nabla h(p^*) = 0, \mu^* \geq 0$$

不等式 $\rightarrow h(p^*) < 0, \mu^* = 0$

等式 $\rightarrow h(p^*) = 0, \mu^* \geq 0$

KKT条件:

$$\mathcal{L}(p, \lambda, \mu) = \dots$$

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial p} = \nabla F(p^*) - \sum_{i=1}^m \lambda_i \nabla g_i(p^*) - \sum_{j=1}^n \mu_j \nabla h_j(p^*) = 0 \end{cases}$$

等式约束 不等式约束

$$\frac{\partial \mathcal{L}}{\partial \lambda} = g_i(p^*) = 0, \quad \frac{\partial \mathcal{L}}{\partial \mu} = h_j(p^*) \leq 0$$

$$\mu_j \geq 0$$

$$\mu_j h_j(p^*) = 0$$

针对不等式约束

$\Rightarrow$ 求出 p 的范围

分类讨论 $\begin{cases} \mu_j = 0 \end{cases}$

$$\mu_j \neq 0 \Rightarrow h_j(p^*) = 0$$

有 n 个, 则讨论 2^n 次

代入 p , 看是否满足

然后找最小的 $F(p)$

优化梯度下降

$$F(p + \Delta \vec{p}) \approx F(p) + \nabla F(p)^T \Delta \vec{p}$$

p 附近的面用切面来近似, 无法直接得到极值点位置

$\therefore$ 引入二次项

$$F(p + \Delta \vec{p}) \approx F(p) + \nabla F(p)^T \Delta \vec{p} + \frac{1}{2} \Delta \vec{p}^T H \Delta \vec{p}$$

碗形近似, 可直接一步求最小值
比梯度下降快

$$H = \begin{vmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{vmatrix}$$

$$\nabla F(p) + H \Delta \vec{p} = 0$$

$$\Delta \vec{p} = -H^{-1} \cdot \nabla F(p), \text{ 极值点}$$

二次规划:

常数项不影响极值点

$$\text{令 } F(x) = \frac{1}{2} x^T P x + Q^T x + \dots \quad \text{可忽略}$$

$$\mathcal{L}(x, \lambda, \mu) = F(x) + \lambda^T g(x) \quad \leftarrow g(x) \text{ 为约束}$$

KKT:


MPC 模型预测控制

估计/观测当前系统状态 y_k

预测 $u_k, u_{k+1} \dots u_{k+N-1}$ (输入 (也可视为控制量))

基于 $u_k, u_{k+1} \dots u_{k+N-1}$ 做最优化

只施加 u_k



使用二次规划来做最优化

$$F(x) = x^T P x + Q^T x$$

输出: $y_k = A y_{k-1} + B u_{k-1}$

$\downarrow$
 $\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$

$\downarrow$
 $\begin{bmatrix} u_1 \\ \vdots \\ u_k \end{bmatrix}$

输入

k时刻的预测输入:

$u_k/k \quad u_{k+1}/k \quad \dots \quad u_{k+N-1}/k$

预测状态:

$y_k/k \quad y_{k+1}/k \quad \dots \quad y_{k+N-1}/k$

参考值: y 最后要达到的值

y_k

预测区间

预测状态量:

$$Y(k|k) = Y_k \leftarrow \text{初态}$$

$$Y(k+1|k) = AY(k|k) + BU(k|k)$$

$$Y(k+2|k) = AY(k+1|k) + BU(k+1|k) = A^2Y(k|k) + ABU(k|k) + BU(k+1|k)$$

⋮

$$Y(k+N|k) = A^N Y(k|k) + A^{N-1}BU(k|k) + \dots + BU(k+N-1|k)$$

Y_k

$$Y_k = \underbrace{\begin{bmatrix} E_n \\ A \\ \vdots \\ A^N \end{bmatrix}}_{(n+1)} Y(k|k) + \underbrace{\begin{bmatrix} 0 & 0 & \dots & 0 \\ B & & & \\ AB & B & & \\ \vdots & \vdots & \ddots & \\ A^{N-1}B & A^{N-2}B & \dots & B \end{bmatrix}}_{n \times (n+1)} \underbrace{\begin{bmatrix} 0 \\ u(k|k) \\ u(k+1|k) \\ \vdots \\ u(k+N-1|k) \end{bmatrix}}_{\substack{u: 1 \sim n-1 \\ \text{不用第 } n \text{ 次}}}$$

M 模型矩阵?

C 控制矩阵?

↓

$$Y_k = MY(k|k) + CU_k$$

使输入和
末端误差最小的总
罚项

令: 代价函数 J

$$J = \underbrace{\sum_{i=0}^{N-1} [Y(k+i|k) - R]^T P [Y(k+i|k) - R]}_{\text{误差加权平方和}} + \underbrace{u(k+i|k)^T \cdot S \cdot u(k+i|k)}_{\text{输入加权项}} + \underbrace{[Y(k+N|k) - R]^T \cdot U \cdot [Y(k+N|k) - R]}_{\text{预测最末端的误差}}$$

$$= \begin{bmatrix} Y(k|k) - R \\ Y(k+1|k) - R \\ \vdots \\ Y(k+N|k) - R \end{bmatrix}^T \begin{bmatrix} P & & \\ & P & \\ & & \ddots \\ & & & P \\ & & & & U \end{bmatrix} \begin{bmatrix} \\ \\ \\ \\ \end{bmatrix}$$

$$= (Y_k - R)^T \bar{P} (Y_k - R)$$

$$J = (Y_k - R)^T \bar{P} (Y_k - R) + U_k^T \cdot S \cdot U_k$$

$$= (M Y(k|k) + C U_k - R)^T \bar{P} (M Y(k|k) + C U_k - R) + U_k^T \cdot S \cdot U_k$$

$$\sum E = M Y(k|k) - R$$

$$k) J = (E + C U_k)^T \bar{P} (E + C U_k) + U_k^T \cdot S \cdot U_k$$

$$= (E^T \bar{P} + U_k^T C^T \bar{P}) (E + C U_k) + U_k^T \cdot S \cdot U_k$$

$$= \underbrace{E^T \bar{P} E}_{\text{常数项, 可忽略}} + \underbrace{E^T \bar{P} C U_k + U_k^T C^T \bar{P} E}_{\text{这两相等, 是标量}} + U_k^T C^T \bar{P} C U_k + U_k^T \cdot S \cdot U_k$$

$$= 2 E^T \bar{P} C U_k + U_k^T (C^T \bar{P} C + S) U_k$$

$$\sum f^T = 2 E^T \bar{P} C U_k, \quad H = 2 (C^T \bar{P} C + S)$$

$$k) J = \frac{1}{2} U_k^T H U_k + f^T U_k$$

~~$$X_k = X_{k-1} + (X_{k-1} - 3) \cdot \Delta r \Rightarrow X_k = (\Delta r + 1) X_{k-1} - 3 \Delta r$$

$$y_k = y_{k-1} + 10(X_{k-1} - 3) \cdot \Delta r \Rightarrow y_k = 10(\Delta r + 1) y_{k-1} - 30 \Delta r$$~~

~~$$X = \begin{bmatrix} X_k \\ y_k \end{bmatrix}$$~~

~~$$X_k = \begin{bmatrix} \Delta r + 1 & 0 \\ 0 & 10\Delta r + 10 \end{bmatrix} X_{k-1} + \begin{bmatrix} -3 \\ -30 \end{bmatrix} \Delta r$$~~

A

B

预测 N 次

$$X_k = X_{k-1} + U_{k-1}$$

$$X(k|k) = X(k|k)$$

$$X(k+1|k) = X(k|k) + U(k|k)$$

$$X(k+2|k) = X(k|k) + U(k+1|k) + U(k|k)$$

⋮

$$X(k+N|k) = X(k|k) + U(k+N-1|k) + \dots + U(k|k)$$

$$U_k = \begin{bmatrix} U(k|k) \\ \vdots \\ U(k+N-1|k) \end{bmatrix}_N$$

$$X_k = \begin{bmatrix} E \\ E \\ \vdots \\ E \end{bmatrix} X(k|k) + \begin{bmatrix} 0 & 0 & \dots & 0 \\ E & \vdots & & \\ \vdots & \ddots & & \\ E & \dots & & E \end{bmatrix} U_k$$

$\downarrow$
 $= M$

$\downarrow$
 $= C$

$$X_k = M X(k|k) + C U_k$$

$$X = \begin{bmatrix} x \\ y \end{bmatrix},$$

$$R = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$$

